

无感知测评心理健康对话评估智能体

阶段性设计进展报告

汇报周期：2026 年 7 月 20 日至 7 月 21 日 | 汇报日期：2026 年 7 月 21 日

本阶段结论：前期访谈需求已经开始转化为可实施的智能体设计。两日工作聚焦两个层次：周一确定系统定位、边界和总体模块；周二形成核心对话流程及安全中断分支。当前成果为第一版设计框架，尚未进入 Coze 实现和真实用户测试。

1. 前期研究与本阶段任务

前期共整理 6 份心理咨询师/高校心理工作者访谈和 5 份精神科相关访谈，形成 183 条开放编码，并围绕“专业评估需要覆盖什么”和“自然语言系统如何安全承接评估”两个研究问题完成需求提炼。访谈结果表明，系统应重点覆盖主诉、持续时间、情绪与身体状态、功能影响、支持系统和危机风险，同时保持非诊断定位、危机优先和人工复核。

因此，本阶段不再继续扩展访谈结论，而是选择其中最基础、最优先的需求，先回答两个设计问题：

周一：系统是什么

明确产品定位、能力边界、核心功能模块及模块之间的关系，形成总体设计草案。

周二：系统怎么运行

把总体框架转化为核心对话步骤，并设计危机线索出现后的中断和人工复核位置。

2. 周一工作：智能体总体框架

2.1 系统定位与能力边界

智能体采用**对话助手**形式，定位为“**高校心理健康对话评估助手**”。它通过自然语言对话帮助学生梳理近期困扰，采集初步评估信息，识别需要优先关注的风险线索，并形成结构化记录。完整评估报告仅进入后台，供心理中心老师查看和复核，不直接展示给学生。

系统可以做	系统不能做
开放式了解用户主诉和求助目标	宣称自己是心理咨询师或精神科医生
补充时间、频率、强度和功能影响	输出确定性疾病诊断或排除诊断
识别风险线索并切换安全流程	提供药物调整、治疗承诺或紧急救援承诺
整理报告草稿并提交人工复核	把模型输出直接当作最终专业结论

2.2 核心模块划分

本阶段先保留六个直接支撑最小闭环的模块，不在汇报中展开完整知识库、量表和后台配置细节。

M1 知情说明与边界

说明用途、限制、数据使用以及暂停、跳过和退出权利。

M2 主诉信息收集

先让用户自由表达，再确定本次最需要梳理的问题。

M3 动态追问

围绕用户原话补足时间、频率、强度、情境和功能影响。

M4 安全风险识别

对每轮输入持续监测，发现风险后中断普通流程。

M5 结构化报告

区分用户原话、系统归纳、信息缺口和建议方向。

M6 人工复核

由授权专业人员确认风险、报告和后续处理建议。

2.3 简化总体架构



图 1 智能体总体架构（第一版草案）

3. 周二工作：核心对话流程

周二工作是在总体框架上确定一条能够支持后续原型实现的主流程。流程采用“**主诉驱动 + 必要字段补全**”，不要求用户从头到尾填写完整问卷，也不以一次对话问完所有字段为目标。

3.1 正常对话主流程




图 2 核心对话流程。安全监测同时覆盖全部阶段，而非只在第⑤步运行。

阶段	主要任务	完成条件
边界说明	说明系统是初步评估和信息整理工具，用户可跳过、暂停、退出和更正	用户理解并同意继续
开放式主诉	了解用户当前最困扰的事情和本次求助目标	形成至少一个主要议题
具体化追问	围绕主诉补充发生情境、持续时间、频率、强度和近期变化	主诉具备基本时间和影响信息
状态与影响	按相关性了解情绪、认知、行为、睡眠饮食及学习生活影响	至少确认一个主要功能领域
安全确认	即使前文没有主动披露，也以中性问题确认当前安全	得到明确回答或转入安全分支
总结与反馈	中性复述已确认事实，说明信息缺口，邀请用户修正	用户确认或选择不再补充
报告与复核	将已确认、未知、拒答和冲突字段分别记录，生成草稿	完成自动校验并进入对应复核队列

3.2 每轮对话的控制原则

先检查安全

每轮输入先识别即时危险和风险线索，再处理普通评估内容。

一次一个重点

常规情况下每轮只问一个主要问题，减少用户负担和问卷感。

不重复已知信息

记录已确认、未知、拒答和冲突状态，避免反复询问。

不把模糊回答当结论

“还行”“没事”“一般”需要结合上下文澄清，不能自动记为正常。

3.3 从自然表达转为结构化信息

系统需要在不打断表达的情况下，把用户回答转换为后续报告可用的字段。每个字段至少记录**内容、状态、来源和证据位置**；未询问、用户拒答和用户明确否认必须分别处理。

用户表达	结构化记录	下一步
“最近一个月总是两三点才睡。”	睡眠变化：入睡困难；持续约一个月；来源为用户明确陈述	追问出现频率及白天影响
“还行吧，不太想说。”	当前程度未确认；用户暂不愿展开	尊重跳过，不记录为“没有影响”
“以前有过这种想法，现在没有。”	既往风险与当前风险分别记录	简短确认当前安全与可用支持

3.4 对话示例

用户：最近论文和找工作一起压过来，晚上总睡不着。

智能体：论文和求职同时推进，确实容易让人一直绷着。你提到晚上睡不着，这种情况大概持续多久了？

设计说明：先承接用户已表达的压力，再追问一个关键维度；不在第二轮直接判断“焦虑”，也不立即投放完整量表。

4. 安全中断与人工复核

访谈和 Miro 整理均表明，危机风险不能只在对话末尾检查。因此，本阶段在正常流程之外增加一条全局安全通道：任意阶段出现自伤、自杀、伤人、已经发生的身体伤害或严重精神状态线索时，系统立即暂停普通追问、量表和自助建议。

4.1 安全分支流程




图 3 危机线索触发后的安全中断分支（初步设计）

4.2 初步分流方向

当前只确定 workflow 方向，不把系统标签当作临床风险等级，也不让模型单独作出最终处置决定。

流程状态	适用情况	后续动作
继续评估	本次对话当前未披露明确即时风险，回答较一致	继续主诉与功能影响评估，同时保留不确定性
需要关注	存在消极想法、明显功能下降、既往风险或支持不足	补充必要信息，建议尽快联系专业支持，进入人工复核
高度关注	存在主动风险意念、计划或工具可及，或无法稳定确认安全	停止普通流程，立即连接现实支持和专业资源
紧急处理	行为正在发生、已经受伤/疑似过量服药，或计划迫近	建议立即联系当地紧急服务、医疗机构和现场可信任人员
信息不足	风险表达后拒答、退出、输入冲突或技术中断	不得记录为“无风险”，按保守原则提示资源并人工复核

4.3 安全规则的实现原则

多通道识别 关键词模式、语义理解、量表风险条目和会话历史共同提供线索，避免只看单个词语。	只问必要信息 确认当前行为、想法、时间、现实支持和能否保持安全，不追问无助于分流的伤害操作细节。
资源必须受控 热线、医院和校内联系人只能来自项目组审核并定期维护的白名单，系统不得临时编造。	模型不能自动解除风险 用户改口、拒答或信息冲突时保留原始记录，必要时继续人工复核。

4.4 报告与人工复核

对话结束后，系统生成的只是**报告草稿**。草稿需要区分用户原话、系统归纳、尚未确认的信息和风险提示，并保留对应证据。以下情况必须进入人工复核：

- 出现任何自伤、自杀、伤人或严重精神状态线索；
- 用户拒绝关键安全问题、回答存在冲突或中途退出；
- 系统准备给出专业转介建议；
- 量表结果与用户叙述明显不一致；
- 报告中存在需要专业人员确认的判断性表述。

环节	系统职责	专业人员职责
信息整理	提取字段、标明来源和缺口	核对是否符合用户原意
风险提示	根据规则触发安全流程并记录依据	确认风险及现实处置方向
报告生成	生成非诊断性的结构化草稿	修改、驳回或确认后发布

当前边界：学校危机资源白名单、人工响应责任、服务时间和第三方联系条件尚未确认。因此，这部分目前只能用于设计评审和模拟案例测试，不能表述为已经建立真实危机干预能力。

5. 两日阶段成果

“完成第一版框架并形成可评审材料”，并非完成全部智能体设计或系统开发。

- 已形成** 总体设计草案：明确系统定位、能力边界、六个核心模块及其关系。
- 已形成** 核心对话流程：明确从知情说明、开放式主诉到总结反馈和报告草稿的主要步骤。
- 已形成** 安全中断分支：明确风险优先、停止普通流程、连接现实支持和人工复核的基本逻辑。
- 待细化** 提示词与报告字段：已有设计方向，仍需结合组内意见压缩为可在 Coze 中实现的版本。
- 待细化** 方案流程具体细节：已有一个大体的框架，在细节上还需要完善
- 未实施** 平台与测试：尚未在 Coze 中搭建工作流，也未开展模拟案例或真实用户测试。

6. 当前方案的核心特点

设计特点	具体体现	对应访谈需求
主诉驱动	先让用户自由表达，再补齐必要字段	减少固定选项诱导和问卷感
动态追问	围绕时间、频率、强度、情境和功能影响逐步澄清	避免仅凭情绪关键词下结论
风险优先	每轮安全监测，出现风险后中断普通流程	回应危机识别与转介闭环要求
证据可追溯	字段记录来源、状态和证据位置	支持专业人员审计和修正
人机协作	AI 生成草稿，专业人员完成关键判断	保持系统边界并降低误导风险

7. 下一步工作

- 完成组内评审**：确认量表使用范围、安全责任链、数据权限和原型测试边界。
- 细化关键规则**：在当前流程上完善各阶段提示词、字段状态和报告结构。
- 确认安全条件**：由专业人员审核安全问题和分流逻辑，并建立有效的资源白名单和人工责任链。
- 实现最小原型**：优先打通边界说明、主诉收集、动态追问、安全确认、总结和结构化输出。
- 开展模拟测试**：使用专家编写的标准化案例验证风险漏报、重复提问、诊断性措辞和报告一致性。

8. 需要组内确认的问题

智能体采用对话助手形式、完整评估报告仅提供给后台老师，这两项已经明确。后续仍需组内确认以下问题：

序号	待确认问题	对后续工作的影响
1	原型阶段允许使用哪些量表，题目、计分和结果解释由谁审核？	影响量表路由和对话流程
2	危机资源由谁维护，出现高风险时由谁接收并处理人工告警？	决定安全分支能否进入真实测试
3	对话记录、后台报告和身份信息如何分开保存，哪些角色可以访问？	影响 Coze、飞书和自研平台的数据设计

汇报结论：两日工作已经完成从“访谈需求”到“总体框架和核心流程”的第一步转化。下一阶段重点不是继续增加文档数量，而是通过组内和专业评审确定边界，再将关键流程压缩为可实现、可测试的 Coze 最小原型。