

暑期科研实训第二次会议纪要

时间：2026年7月21日 15:11，时长约 55 分钟

参会人：宋泽坤（指导学长）、李锦程、颜浩轩

Summary

本次会议围绕两个子项目的进展展开：心理预警建模（李锦程）和无感知测评智能体设计（颜浩轩）。建模方面，核心问题是 Cat4 仅 11 条数据导致预测几乎完全失效（精确率/召回率均为 0%），会议决定大幅简化目标——合并小样本类别，只输出整体风险概率和特征重要性，不再追求精确的 Cat 分类或四级关注级别判定。智能体方面，颜浩轩完成总体设计草案，确立了六阶段核心对话流程和安全性全局中断机制，明确了 PHQ-9/GAD-7 量表作为评估依据，选定了 NK-GNOS 平台 + 自建前后端 + 飞书多维表格的技术架构。此外还讨论了计算资源（禁止将数据上传校外云平台）、AI 工具费用报销、后续论文写作机会以及实训成绩评价标准。

一、心理预警建模进展与决策

1.1 当前进展

李锦程汇报了周末至周日的建模工作（会议开始时因录制缺失，这部分为结合设计文档的还原）：

- 已完成 Cat1-Cat4 条件分类模型（C0/C1/C1-R）和关注级别有序模型（L0/L1/L1-R）的训练与测试
- 性能表现：Cat1 精确率/召回率约 60%/70%，尚可接受；Cat2 精确率约 35%、召回率约 31%，有提升空间
- Cat3 精确率/召回率仅约 28%/27%；**Cat4 精确率/召回率均为 0%**，模型几乎没有识别能力
- Cat4 失效的直接原因：数据量仅 11 条，本科四级仅 1 条，任何模型都无法从如此少的样本中学习有效模式
- 关注级别模型同样不理想：L $\geq$ 2 和 L $\geq$ 3 的精确率/召回率均很低（L $\geq$ 3 甚至无正例预测产出）
- 李锦程推测不同心理问题类别在机器学习嵌入空间中的分布距离可能是影响分类准确率的潜在因素：Cat1 可能聚集在空间的某一区域，而 Cat4 则在另一区域，Cat3 的一级可能位

于中间位置，空间分布的不均匀可能导致了分类边界的模糊。下一步计划按此猜想进行针对性测试

- 如果嵌入空间分析仍不能解决问题，需要考虑对分类体系做进一步划分以提升预测准确率
- 另外使用 LaTeX 模板撰写了周报，认为比直接用 Word 更适合 AI 辅助写作的场景

1.2 宋泽坤的方向性调整决策

宋泽坤在听取汇报后，提出根本性地简化项目目标：

调整的核心理由：

1. 心理发展中心的老师（无论文科还是理科背景）对机器学习模型的预测结果存在天然的不信任，每个结果都需要人工核查，模型无法替代人工判断。“不能说你说他高危他就高危，这不合适。”
2. 从业务角度，无论 Cat1-Cat4 的哪个类别，最终处置逻辑是相通的：高风险需预警观察/访谈，中风险需关注，低风险无需干预。关键信息是“他是高风险的概率有多大”，而不是“他到底是哪种心理问题”。
3. 现有数据质量本身限制了模型精度的上限——“数据质量这么低，咱也怨不了谁”。不同于学术论文中通过专业设备连续采集的时序数据，学校的真实世界数据零星且杂乱，该有的字段经常缺失。

具体调整：

原方案	调整后
精确分类 Cat1-Cat4	将 Cat3、Cat4 合并至大样本类别（至少合并 Cat4），或干脆不区分 Cat，只输出整体风险概率
追求 Cat 级别和关注级别的精确预测	有方法论路径即可，附上精确率/召回率数据，不对数值本身苛求
精细区分一至四级关注级别	分高/中/低三档风险：高风险需访谈或叫到心理中心进一步评估，中风险需观察，低风险无需干预

三周后的最终交付物：

1. **整体风险概率预测**：输出全校学生获得高风险/中风险/低风险的概率，附带精确率和召回率数据。不需要给出具体的 Cat 或级别标签。
2. **特征重要性分析**：哪些因素对预警等级影响最大，以表格形式呈现每个因素的贡献权重。
 - 建议将细粒度特征（如单个运动指标、单个学业指标等每次仅贡献 1%-2% 的小因子）**聚合为大维度**（如学业数据、心理测评数据、行为数据等），使可视化结果更直观、更具说服力。“如果每次只有 1%、2%，他们看着也没什么感觉。”
3. **前端页面优化**（低优先级）：第三周有富余时间再做，没有时间可以不做。“在模型问题面前，页面优化的优先级肯定是要往后排的。”

1.3 真实世界数据的学术价值与论文方向

宋泽坤进一步阐释了该项目所面临的真实世界数据场景的独特学术价值：

- 学术文献中，大多数心理预警研究依赖专业采集设备，在固定时间窗口内连续采集特定学生的时序数据（如连续数月的运动、睡眠、社交等高频信号），因此预测精度较高
- 本校数据与之根本不同：它不是专门为研究采集的，而是学校业务系统在日常运行中自然产生的碎片化记录，经常存在"缺这块、少那块"的情况
- **心理问题具有时序性**：它不是今天突然出现的——"不是说这周能出来，或者今天突然就有了，它肯定有个过程。"因此专业设备采集的连续时序数据天然更适合预测。而本校数据缺乏这种完整的时序覆盖，预测难度更高
- 正因为如此，如果本项目能够在这种低数据质量的真实场景下产出一个具备参考价值的方法论，就具备在其他高校复用的指导性意义——这正是真实世界研究的核心价值，是许多依赖精良数据的论文所不具备的实践意义
- 后续论文路径：算法方案 + 特征重要性分析 + 心理中心教师访谈 = 完整的混合方法研究文章

二、计算资源与 AI 工具

2.1 校外云计算平台使用申请（被否决）

李锦程提出，本机在训练机器学习模型时耗时过长，希望将数据上传至 AutoDL 等云计算平台进行训练。他指出，机器学习训练主要消耗的是 CPU 资源而非 GPU，而他当前使用的机器 CPU 性能确实捉襟见肘。

宋泽坤明确否决了这一请求：

- **核心问题**：数据包含学生隐私信息，上传校外平台存在数据安全和合规风险，不被允许
- **替代方案一**：将代码和数据打包发送至宋泽坤的个人机器，由宋泽坤代为训练
- **替代方案二**：申请使用学院组内服务器——原为海林老师组学生独占的 8 张 V100 服务器，现已因资源紧张而开放为全院共享，但全院同学都在上面跑任务，"卡得不行"，不确定是否能排上
- 最终共识：如果方便打包就代为训练，不方便的话就以出方案为主，不一定需要反复训练。**"我们只需要出方案就行了，不用太去训练。"**

2.2 AI 工具使用费用

李锦程反映近期 AI 工具使用量激增，两个账号（opencode 的 Claude 模型和 ChatGPT Plus）均已达到使用限额，且两天未见重置。

使用场景说明：

- 写代码时的策略：先用 ChatGPT Plus 最新模型规划方案，再用国产模型执行代码编写，已经在有意识地节省用量
- 优化了好几个版本，尽管已经"省着用"了，仍然消耗了大量额度

解决方案讨论：

- 颜浩轩推荐其使用的 GPT 镜像站：
 - 价格参考：此前的 GPT-4（5.4 版本）较为便宜，当前使用 GPT-5.5 Pro 模型成本稍高但仍可接受
 - 本学期初充值七八十元，至今还剩十多元，日均花费不高
 - 策略：将文档类任务交给国产大模型处理，GPT 仅在关键的复杂推理中调用，以此控制成本
- 李锦程分享经历：此前做 Rust 课程作业时，使用镜像站一天花费近 10 元，一个作业合计花费近 200 元；使用的镜像站定价为 5.5 元/次的 Pro 模型，价格可能偏高

宋泽坤的报销方案：

- 项目产出的 AI 工具费用**尽量报销**
- 条件是：能开具正规发票，不能是"稀奇古怪的票"
- 如需新增 ChatGPT Plus 账号，提供购买链接，由宋泽坤充值，小红书上找能开票的卖家
- 提醒不要因费用问题而束手束脚，但也不要花费过高导致报销困难
- 费用合理性参考：此前办活动打印资料花费 1000 多元，只要用途合理、发票正规，报销一般不会有问题

三、无感知测评智能体设计

3.1 总体设计目标与边界

颜浩轩汇报了产品设计的定位：参考上周对任务进行编码细分的结果，明确智能体框架设计和后续对话流程。

核心需要回答的三个问题：

1. 智能体框架应设计成什么样
2. 整个对话流程是什么样的
3. 产品的定位边界、核心功能模块及模块之间的联系

本周产出：形成了包含上述三点的总体设计草案。

3.2 核心对话流程（六阶段+八步骤）

智能体核心功能模块划分为六个阶段：

序号	模块	说明	完成条件
1	知情说明与边界	说明系统是初步评估和信息整理工具，用户可跳过、暂停、退出和更正	用户理解并同意继续
2	开放式主述	了解用户当前最困扰的事情和本次求助的目标	形成主要议题
3	动态追问	围绕主述补充发生情境、持续时间、频率、强度和近期变化	补充到基本的时间和影响信息
4	状态与影响	了解用户关于情绪、认知、行为、睡眠、饮食及学习生活的影响	至少明确一个主要受影响的领域
5	安全确认	全程嵌入的全局通道，每轮对话均需检测安全风险	得到明确安全回答，或转入安全风险处理分支
6	结构化报告 + 人工复核	生成结构化报告并提交后台，由人工进行复核	用户确认或不再补充信息，报告生成完成

3.3 对话设计原则（四项规则）

原则	说明
逐领域询问	常规对话中每次只询问用户一个领域的负担，避免同时抛出多个问题造成问卷式的压迫感
不重复已确认信息	在后续回答中不应重复用户已经确认过的信息，避免反复追问同一内容
模糊回答不当结论	"还行""没事""一般"等语气词不能直接标记为"正常"，必须结合上下文进行二次确认
自然表达结构化	将用户的日常表达转化为结构化的关键信息记录

结构化转换示例：

- 用户说"最近一个月总是两三点才睡"→ 系统记录：睡眠变化（入睡困难）、持续时间（约一个月）、来源（用户自述）；并据此生成下一轮追问方向
- 用户说"还行吧，不太想说"→ 系统标记为"当前程度无法确认，用户不愿展开"（风险未知/RX），尊重用户跳过，但不意味着该领域"无影响"
- 用户说"以前有过那种想法，现在没有了"→ 系统区分记录：既往风险 vs 当前风险，分别标记

对话示例：

用户：「最近论文和找工作一起压过来，晚上总睡不着。」

智能体：「论文和求职同时推进，确实让人绷着。你提到晚上睡不着，我想问问这种情况大概持续多久了？」

设计要点：先承接用户已表达的压力（共情），再沿着一个维度追问（聚焦），不直接给出"焦虑"判断，也不直接让用户填表。让对话保持自然而非问卷式。

3.4 安全保障机制（全局通道）

核心理念： 风险检查不能在对话的结尾或某个固定时间点才触发，必须是**贯穿全流程的全局通道**。

从整个对话流程的角度，安全确认具体细化为八个步骤：

步骤	内容
1	边界说明——系统是初步评估和信息整理工具，用户可跳过/暂停/退出/更正；完成条件：用户理解并同意
2	开放式主述——了解困扰和目标，形成主要议题
3	具体化追问——围绕主述补充情境、持续、频率、强度和变化
4	状态与影响——情绪/认知/行为/睡眠/饮食/学习生活，至少明确一个主要影响领域
5	安全确认（全程） ——每轮对话输入输出时检测危险和风险线索；得到明确安全回答或转入风险分支
6	总结与反馈——用户确认或不再补充
7	结构化报告生成
8	提交后台人工复核

触发条件与响应： 发现明确或含蓄的风险线索时：

- 立即中断常规评估流程
- 确认用户当前是否安全、是否可用、是否需要外部帮助
- 调用可用资源（心理中心联系方式等），为后续人工复核提供交接依据
- 任何发现的风险线索都必须在报告的原始记录中保留，不能因为后续对话的正常进行而将其删除

风险等级五层划分：

等级	含义	处置方向
继续评估	未展示安全风险	正常对话继续
需要关注（一级）	存在需要关注的信号	继续评估并标记
高度关注（二级）	存在较明确的担忧	加强关注，优先推送
紧急处理（三级）	存在当下危险	立即推送资源，中断对话
信息不足（RX）	用户未展开，无法确认	标记为风险未知，尊重用户边界

安全机制的四项铁则：

1. **多通道识别**：在用户的所有表达中（文字、情绪、回避、模糊用词等）综合识别风险线索；只问必要信息，不追问可能无助于安全的操作细节
2. **不追问操作细节**：不允许追问可能助长伤害的具体方法、地点、工具等细节，"这种事越问越危险"
3. **资源必须受控**：系统提供的热线号码、救助渠道等必须来自官方确认的可靠来源，禁止大模型生成幻觉编造热线号码
4. **风险不可自动消除**：模型标记的风险记录必须原样保留，不能因对话后续走向正常而自动删除或降级——原始记录是人工复核和后续追溯的唯一依据

3.5 结构化报告与人工复核

报告需要区分的信息层次：

- 用户原话（原文引用，不可篡改）
- 系统归纳的信息（结构化提炼后的描述）
- 尚未确认的信息（用户表达模糊或不愿展开的部分，标记为 RX）
- 风险提示（安全检测发现的线索及对应等级）

报告中安全风险类需要进入人工复核的情况：

- 用户在对话中出现了需要关注及以上等级的风险信号
- 报告中存在明确的危机线索
- 报告中的某些领域标记为 RX（信息不足、风险未知），无法排除风险

当前待解决问题：

- 报告提交的具体渠道和接口尚未确定（后台对接方式、数据流转路径待明确）
- 目前已模拟了一个安全报告的基本流程，但报告生成的字段细节、提示词设计、具体操作流程仍需要在后续阶段细化

3.6 下一步需要细化的工作

- 智能体提示词的具体内容设计（如何用提示词实现上述对话流程和原则）
- 报告字段的具体定义（包含哪些维度、每个维度的取值和格式）
- 从总体草案到实际平台实现的过程中，每个对话步骤的具体设计和落地细节
- 端到端流程测试（尚未进行，因为具体设计尚未完成）

设计理念总结为四个关键词：**主述驱动 + 动态追问 + 风险优先 + 证据可追溯**，强调人机协作而非机器自动决策。

四、评估量表与技术方案确认

4.1 评估量表

颜浩轩提出三个问题，宋泽坤逐一回应：

(1) 心理评估采用什么量表标准？

采用 **PHQ-9**（9 条目患者健康问卷，用于抑郁筛查）和 **GAD-7**（7 条目广泛性焦虑障碍量表，用于焦虑筛查）。按照这两个量表的维度进行询问即可。

(2) 安全分支之后的后续流程是怎样运作的？

受限于平台技术能力，无法实现实时弹窗或直接接入心理中心，采用以下三层机制：

- **对话中**：在聊天框内推送心理发展中心的联系电话等资源信息
- **报告中**：在最终报告里标记风险等级（高危等）
- **报告后**：报告导出至**飞书多维表格**。多维表格支持设置新增记录提醒——当新增一条高危记录时，自动通知心理发展中心老师。老师查看报告后根据等级（如高危）直接联系学生进行干预或访谈

宋泽坤指出：NK-GNOS 平台本身不太可能支持"对话中突然弹出心理中心老师介入"这种复杂交互。在平台上搭建智能体，然后接到自建前后端上，发挥空间更大、也更可行。

(3) 报告生成后信息如何保存？

通过 NK-GNOS 平台的工作流连接飞书多维表格，将报告（含姓名/时间/风险等级/详细内容）写入多维表格。需要修改 token 等配置，换成自己的飞书多维表格。

4.2 平台架构总览

完整的技术方案线路：

用户在智能体对话 → 报告生成 → NK-GNOS 工作流 → 飞书多维表格 → 心理中心老师查看 → 人工干预

- **智能体搭建**：NK-GNOS 平台（含提示词设置 + 工作流配置）
- **前后端**：自行搭建，包含管理员页面和用户页面。"优先实现一整套流程能跑通"——即用户测评后所有报告都能反馈到飞书多维表格中
- **工作流集成**：NK-GNOS 已有飞书多维表格的连接能力，调整 token 配置即可
- **多维表格通知**：设置新增高危记录时的自动提醒

4.3 前端开发优先级

- 前后端中的管理员页面和用户页面，如果工作量过大，按实际情况灵活调整
- 核心原则：**优先跑通完整流程**（测评 → 报告 → 飞书多维表格），页面优化在流程跑通之后再考虑

五、后续工作安排与论文机会

5.1 本周任务

负责人	任务	说明	截止时间
李锦程	按简化方案继续优化模型	合并小样本类别，聚焦风险概率与特征重要性	持续进行
颜浩轩	在 NK-GNOS 搭建初步智能体	设置提示词，不要求很完善，有基本对话能力即可	周三提交报告前

对于智能体搭建任务，宋泽坤的解释是：

- 不要求质量有多好，但**必须先有一个能跑起来的版本**，这样在周报中"有点东西"，能体现出从设计到实现的推进
- 如果还没搭建出来，这周的工作产出就只停留在设计方案上，会显得单薄。加上"初步智能体已搭建"这一条，周报内容就更充实

5.2 日常工作要求

- 今天先完成周报，再补日报（日报简要记录即可）
- 明天提交周报前发到群里，让大家预览，确保格式和内容"写得漂亮"
- 周报要**充分体现所有工作内容**，不要遗漏

5.3 论文写作机会

宋泽坤为两人分别梳理了论文学术产出的可能性（强调论文写作不影响实训成绩，自行决定）：

预警方向（李锦程）：

- 路径：真实世界数据预测方法 + 特征重要性分析 + 心理中心教师访谈 → 混合方法研究论文
- 优势：与依赖专业设备采集精良数据的已有论文不同，本研究的真实世界数据场景具备稀缺的实践参考价值
- 可以包括算法设计、模型选择、特征工程、以及真实数据质量约束下的工程应对策略

测评方向（颜浩轩）：

- 基础：前人在"无感知测评"方向上已发表过一篇 EI 会议论文（workshop）
- 发表新论文的条件：在前人工作的基础上，新工作的拓展部分需**显著超过**前人论文内容（workshop 论文允许在此基础上扩展，通常要求拓展部分占比超过 70%）

- 如果能在在此基础上做出实质性的增量贡献（如新的对话框架、安全机制、系统实现等），就可以再写一篇

5.4 实训成绩说明

宋泽坤对两人当前的实训评估：

- 第一周的工作"都可以，都没有什么问题"
- 鼓励按自己的计划推进，不必因外部压力而打乱节奏
- 技术上遇到难题时随时沟通过程问题，但具体解决方案上，"可能指导得不多，因为第一是不太懂，不太深入"——与其在不太懂的领域强行指导影响你们的思路，不如让你们按照自己的想法走
- 如果需要协调学院老师配合工作、需要其他资源协助，"直接跟我说就行"

六、关键提醒汇总

1. **数据绝不上云**：严禁将包含学生信息的数据上传 AutoDL 等校外平台。训练在本机、宋泽坤机器或学院服务器上完成
2. **简化目标、降低工作强度**：数据质量决定了模型的精度天花板，不必给自己上太大的工作强度。有方法路径即可，不苛求高指标
3. **安全是全局通道**：智能体的安全检测机制不是某个步骤完成后的"事后检查"，而是全程嵌入每个对话回合的即时检测
4. **费用可报销**：项目产生的 AI 工具费用凭正规发票走报销，不要因费用问题束手束脚
5. **周报先行**：今天先写周报再写日报，明天提交前发群预览，确保充分展示工作内容
6. **前端低优先级**：页面优化有精力再做，核心目标是"测评 → 报告 → 飞书多维表格"这一完整流程跑通